

GMRES:求解 NONSYMMETRIC 线性方程组的广义最小残差算法*

YOUCEF SAAD[†] 和 martin H. SCHULTZ[‡]

摘要。我们提出一种求解线性方程组的迭代算法，该算法具有在每一步骤中最小化残差向量在 Krylov 子空间上范数的特性。该算法源自构建 Krylov 子空间 l_2 正交基的 Arnoldi 过程。可视为 Paige 和 Saunders MINRES 算法的推广，其理论等价于广义共轭残差法（GCR）和 orthodir 方法。相较于 GCR 和 orthodir，新算法展现出多项优势。

关键词。非对称系统、Krylov 子空间、共轭梯度法、下降法、最小残差法

AMS (MOS) 受试者分类。65F

1. 引言。求解大型稀疏对称正定线性方程组最有效的迭代方法之一是共轭梯度法与某种预处理技术的结合[3], [8]。此外，近年来针对非对称问题[2]、[9]、[5]、[4]、[13]、[14]以及对称不定问题[10]、[3]、[11]、[14]，已有多种共轭梯度法的推广方法被提出。

为求解不定对称系统，Paige 和 Saunders[10]提出了一种利用共轭梯度法与 Lanczos 法之间关系的方法。具体而言，已知求解 $N \times N$ 矩阵 A 的特征值问题的 Lanczos 法是作用于 Krylov 子空间 $K_k = \text{span}\{v_1, Av_1, \dots, A^{k-1}v_1\}$ 上的 Galerkin 方法，而共轭梯度法则是作用于 Krylov 子空间 K_k （其中 $v_1 = r_0/\|r_0\|$ ）上求解线性方程组 $Ax=f$ 的 Galerkin 方法。因此，Lanczos 法计算线性算子 $PA|_{K_k}$ 的矩阵表示 T_k ，即 PA 在 K_k 上的限制，其中 P_k 是作用于 K 的 l_2 正交投影。在 K_k 中求解 $Ax=f$ 的 Galerkin 方法会导致用三对角矩阵 T_k 求解对称矩阵 fA 的线性方程组。一般而言，当 A 为不定矩阵时 T_k 是不定的，必须使用某种稳定直接方法求解对应的三对角 Galerkin 方程组。Paige 和 Saunders 的 SYMMLQ 算法的核心在于利用 T 的稳定 LQ 分解。佩奇和桑德斯还证明，可以利用 Lanczos 基构建一种名为 MINRES 的算法，通过计算 Krylov 子空间 K_k 上的残差范数最小化来获得近似解 x_k 。

本文提出并分析了一种求解非对称线性系统的 MINRES 算法的推广方法。该推广方法基于 Arnoldi 过程[1], [12]，它是针对非对称矩阵的 Lanczos 算法的类似物。

与 Lanczos 方法对称矩阵求解时生成的 $P_k A|_{K_k}$ 三对角矩阵不同，Arnoldi 方法生成的是上 Hessenberg 矩阵。通过 Arnoldi 过程生成的 l_2 正交基，我们将证明：在 K_k 空间上最小化残差范数的近似解，可通过类似 Paige 和 Saunders 的方法轻松计算。我们将最终结果称为

*本研究由美国海军研究办公室（资助编号：N00014-82-K-0184）及美国国家科学基金会（资助编号：MCS-8106181）共同资助。论文初稿于1983年11月29日由编辑部接收，修订版于1985年5月8日完成。

耶鲁大学计算机科学系，康涅狄格州纽黑文市 06520。

我们采用广义最小残差 (GMRES) 算法。我们将证明 GMRES 在数学上等价于广义共轭残差法 (GCR) [5]、[16] 以及正交方向法 [9]。已知当矩阵 A 为正实矩阵 (即其对称部分为正定矩阵) 时, 广义共轭残差法与正交方向法将生成收敛于精确解的近似序列 x_k 。然而当 A 非正实矩阵时, GCR 可能失效。另一方面, 正交方向法虽不会失效, 但其数值稳定性低于 GCR [5], 尽管这似乎属于标度问题。

因此, 系数矩阵非正实数的系统是开发 GMRES 的主要动机。为便于说明, 考虑以下 2×2 线性系统 $Ax=f$, 其中

$$A = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}, \quad f = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad x_0 = 0.$$

GCR 算法可简要描述如下:

1. 开始: 设置 $p_0 = r_0 = f - Ax_0$
2. 迭代: 当 $i=0, 1, \dots$ 直至收敛时执行:
 - 计算 $\alpha_i = (r, Ap_i) / (Ap_i, Ap_i)$,
 - $x_{i+1} = x_i + \alpha_i p_i$
 - $r_{i+1} = r - \alpha_i Ap_i$
 - $p_{i+1} = r_{i+1} + \sum_{j=0}^i \beta_j^{(i)} p_j$
 - 其中 $\{\beta_j^{(i)}\}$ 的选取需满足 $(Ap_{i+1}, Ap_j) = 0$, 且 $0 \leq j \leq i$.

若尝试对上述示例执行该算法, 将获得以下结果:

1. 在步骤 $i=0$ 时, 我们得到 $\alpha_0 = 0$, 因此 $x_1 = x_0$, $r_1 = r_0$ 。此外, 向量 p_1 为零。

2. 当 computing α_1 时, 算法在步长为 1 时发生除零运算, 导致算法崩溃。

我们将证明, 即使对于具有不定对称部分的问题, GMRES 也无法进行分解, 除非它已经收敛。此外, 我们将证明 GMRES 方法所需的存储空间仅为 GCR 方法的一半, 且比 GCR 少 3 次算术运算。

在第 2 节中, 我们将简要回顾 Arnoldi 方法生成 l_2 正交基向量的方法, 如 [13] 所述。在第 3 节中, 我们将介绍 GMRES 算法及其分析。最后, 在第 4 节中, 我们将展示一些数值实验。

2. Arnoldi 方法。Arnoldi 方法 [1] 利用 Gram-Schmidt 方法计算 Krylov 子空间 $K_k = \text{span}\{v_1, Av_1, \dots, A^{k-1}v_1\}$ 的 l_2 正交基 $\{v_1, U_2, \dots, U_k\}$, 可描述如下。

算法 1: Arnoldi 算法。

1. 开始: 选择一个初始向量 v_1 , 其范数 $\|v_1\| = 1$ 。
2. 迭代: 对于 $j=1, 2, \dots$, do:
 - $h_{ij} = (Av_j, v_i), i=1, 2, \dots, j-1,$
 - $\hat{v}_{j+1} = Av_j - \sum_{i=1}^j h_{ij} v_i$
 - $h_{j+1, j} = \| \hat{v}_{j+1} \|$, 且
 - $v_{j+1} = \hat{v}_{j+1} / h_{j+1, j}$

在实际应用中, 通常更适宜用改进的格拉姆-施密特算法 [15] 替代步骤 2 中的格拉姆-施密特算法。若 V_k 为 $N \times k$

若矩阵的列向量构成 l_2 正交归一基 $\{v_1, v_2, \dots, v_k\}$, 则 $H_k \equiv V_k^T A V_k$ 是上层 $k \times k$ 的Hessenberg矩阵, 其元素由算法1生成的标量 h_{ij} 构成。若将 P_k 定义为 K_k 上的 l_2 正交投影算子, 并用 A_k 表示 A 在 K_k 中的截面(即算子 $A_k = P_k A P_k$), 则可得 H_k 本质上是 A 在基 $\{v_1, v_2, \dots, v_k\}$ 中的矩阵表示。因此Arnoldi的原始方法[1]本质上是一种Galerkin方法, 通过 H_k 的特征值来近似 A 的特征值[1], [12]。

为了解决该线性系统

(1) $Ax=f,$

通过使用 l_2 正交基 V_k 的Galerkin方法, 我们寻求形式为 $x_k = x_0 + z_k$ 的近似解 x_k , 其中 x_0 是解 x 的某个初始猜测, z_k 是Krylov子空间 $K_k = \text{span}\{r_0, A r_0, \dots, A^{k-1} r_0\}$ 的成员, 且 $r_0 = f - A x_0$ 。假设从 $v_1 = r_0 / \|r_0\|$ 开始执行算法1的 k 步。那么很容易看出, Galerkin条件即残余向量 $r_k = f - A x_k$ 与 K_k l_2 正交的条件

$$Z_k = V_k y_k, \text{ 其中 } y_k = H_k^{-1} \|r_0\| e_1$$

且 e_1 是单位向量 $e_1 = (1, 0, 0, \dots, 0)$ [13]。因此我们可以定义以下算法[13]。

算法2:全正交化法。

1.开始: 选择 x_0 并计算 $r_0 = f - A x_0, v_1 = r_0 / \|r_0\|$ 。

2.迭代: 对于 $j=1, 2, \dots, k$ 执行:

$$\begin{aligned} h_{ij} &= (A v_j, v_i), i=1, 2, \dots, j, \\ \hat{v}_{j+1} &= A v_j - \sum_{i=1}^j h_{ij} v_i, \\ h_{j+1,j} &= \|\hat{v}_{j+1}\|, \text{ and} \\ v_{j+1} &= \hat{v}_{j+1} / h_{j+1,j} \end{aligned}$$

3.配制溶液:

$$X_k = x_0 + V_k y_k, \text{ 其中 } y_k = H_k^{-1} \|r_0\| e_1.$$

在实践中, 步骤2中的迭代次数 k 被选择为使近似解 x_k 具有足够的精度。幸运的是, 由于我们可以利用关系式[13]、[14]计算 x_k 的残差范数, 因此无需显式计算近似解, 即可在事后确定 k 足够大的情况。

(2) $\|f - A x_k\| = h_{k+1,k} |e_k^T y_k|.$

需注意, 若算法在第 k 步终止, 则显然无需计算向量 v_{k+1} 。

算法2具有若干重要特性[14]:

·除了一个乘法常数外, x_k 的残差向量 r_k 就是向量 v_{k+1} 。因此, 算法2产生的残差向量彼此 l_2 正交。

·算法2不崩溃当且仅当 v_1 的极小多项式的次数至少为 k 且矩阵 H_k 是非奇异的。

·该过程最多终止于 N 步。

算法2推广了Parlett[11]针对对称情形开发的方法。该算法在数学上等价于Young和Jea[9]开发的orthores算法。

全正交化方法存在一个显著缺陷：随着迭代步数 k 的增加，其计算成本会呈指数级增长。针对这一问题，我们提出了两种有效解决方案。第一种是采用每 m 步重启算法的策略；第二种则是通过截断 l_2 正交化过程——要求新生成的向量 V_{i+1} 仅与前 I 个向量保持 l_2 正交关系（其中 I 为整数参数）。由此得到的Hessenberg矩阵 H_k 将被划分为带状矩阵，算法可据此调整实现方式，仅存储最近 I 个向量 v ，而省去后续数据。关于这种不完全 l_2 正交化方法（IOM(1)）的详细说明，可参阅文献[14]。需要指出的是，这类截断技术的不足在于缺乏关于全局收敛性的理论支撑。由于缺乏类似共轭梯度法的最优性特性，相关理论研究面临较大挑战。在下一节中，我们将基于算法1推导出一种名为GMRES的新方法，该方法能提供满足最优性特性的近似解。

3. 广义最小残差(GMRES)算法

3.1. 该算法。形式为 x_0+z 的近似解，其在 K_k 中对 z 的残差范数最小化，原则上可通过几种已知算法获得：

- Jea和Young的正交定向算法[9]；
- Axelsson法[2]；
- 广义共轭剩余法[4]、[5]。

然而，若矩阵为不定矩阵，这些算法可能会失效或出现稳定性问题。为此，我们提出一种新算法，通过使用Arnoldi方法生成的基来计算相同的近似解，即算法1。

为描述该算法，我们首先注意到：经过 k 步Arnoldi方法后，我们得到一个 l_2 -正交系统 V_{k+1} 和一个 $(k+1) \times k$ 矩阵 H_k ，其中仅非零元素为由该方法生成的 h ；因此 H_k 与 H_{k+1} 相同，只是在 $(k+1, k)$ 位置上增加了一行，其唯一非零元素为 $h_{k+1, k}$ 。向量 v 和矩阵 H_k 满足一个重要关系：

$$(3) \quad AV_k = V_{k+1}H_k.$$

现在我们希望求解最小二乘问题：

$$(4) \quad \min_{z \in K_k} \|f - A[x_0 + z]\| = \min_{z \in K_k} \|r_0 - Az\|.$$

如果我们设定 $z = V_k y$ ，我们可以将最小化的范数视为 y 的以下函数：

$$(5) \quad J(y) = \|\beta v_1 - AV_k y\|$$

为方便起见，我们令 $\beta = \|r_0\|$ 。利用(3)式可得

$$(6) \quad J(y) = \|V_{k+1}[\beta e_1 - Hy]\|.$$

这里，向量 e_1 是 $(k+1) \times (k+1)$ 单位矩阵的第一列。回顾 V_{k+1} 是 l_2 -正交的，我们看到

$$(7) \quad J(y) = \|\beta e_1 - Hy\|.$$

因此，最小二乘问题(4)的解由下式给出

$$(8) \quad X_k = x_0 + V_k y_k$$

其中 y_k 在 $y \in \mathbb{R}_k$ 范围内使函数 $J(y)$ （由公式(7)定义）达到最小值。

所得算法与前文所述的全正交化方法（算法2）相似，唯一区别在于步骤3中用于计算 x_k 的向量 y_k 现被 $J(y)$ 的极小化器所替代。因此，我们定义该方法的如下结构。

算法3：广义最小残差法（GMRES）。

- 1.开始：选择 x_0 并计算 $r_0=f-Ax_0$ 和 $v_1=r_0/\|r_0\|$ 。
- 2.迭代：对于 $j=1,2, \dots, k, \dots$ ，直至满足条件为止：

$$h_i=(Av_j; v_j), i=1,2, \dots, j,$$

$$\hat{v}_{j+1} = Av_j - \sum_{i=1}^j h_{i,j}v_i,$$

$$h_{j+1,j} = \|\hat{v}_{j+1}\|, \text{ and}$$

$$V_{j+1}=0;+1/h_j+1j.$$
- 3.形成近似解：

$$X_k=x_0+V_kV_k, \text{ 其中 } y_k \text{ 使 (7) 式最小化。}$$

在使用 GMRES 算法时，我们可以轻松利用Arnoldi矩阵 H_k 来估计矩阵 A 的特征值。这在[6]提出的混合切比雪夫过程中尤为有用。

显然，我们使用上述 GMRES 方法时遇到的实践困难与全正交化方法相同。当 k 值增大时，需要存储的向量数量与 k 成正比增加，乘法运算次数也相应增加。 $\frac{1}{2}k^2N$ 为解决这一难题，我们可以采用迭代算法，即每 m 步重启一次算法，其中 m 为固定整数参数。这种重启后的算法 GMRES (GMRES)的具体描述如下。

算法4：GMRES (m)。

- 1.开始：选择 x_0 并计算 $r_0=f-Ax_0$ 和 $v_1=r_0/\|r_0\|$ 。
- 2.迭代：对于 $j=1,2, \dots, m$ 执行：

$$h_i=(Av_j; v_j), i=1,2, \dots, j,$$

$$\hat{v}_{j+1} = Av_j - \sum_{i=1}^j h_{i,j}v_i,$$

$$h_{j+1,j} = \|\hat{v}_{j+1}\|, \text{ 且}$$

$$V_{j+1}=0;+1/h_j+1j.$$
- 3.形成近似解：

$$X_m=x_0+V_mV_m, \text{ 其中 } y_m \text{ 使 } \|\beta e_1 - H_m y\| \text{ 最小化, } y \in \mathbb{R}.$$
- 4.重启：

计算 $r_m=f-Ax_m$ ；若满足则停止

else compute $x_0:=x_m, v_1:=r_m/\|r_m\|$ and go to 2.

需注意，在某些应用场景中我们不会重启 GMRES 。例如在求解刚性常微分方程[7]以及混合自适应切比雪夫方法[6]时即属此类情况。

3.2.实际应用。现就 GMRES 的实现方法阐述若干重要细节。以矩阵 H_k 为例，假设需要求解最小二乘问题：

$$\min_y \|\beta e_1 - \bar{H}_k y\|.$$

解决这类问题的经典方法是通过平面旋转将 H_k 分解为 $Q_k R_k$ 。由于 H_k 的特殊结构，这种分解方式实现起来相当简单。但理想情况下，我们希望能在每列数据出现时逐步更新 H_k 的分解结果，即在Arnoldi过程的每一步进行更新。这一点至关重要，因为正如后文将要看到的，这能让我们获得近似解的残差范数。

无需计算 $\mathbf{x}_k$ 即可获得解决方案,从而让我们能够决定何时停止该过程,避免不必要的运算浪费。

我们现在详细说明如何进行这种分解。接下来,我们用 F 表示旋转矩阵,该矩阵将单位向量 $\mathbf{e}$ 和 $\mathbf{e}_{j+1}$ 旋转 θ_j 的角度:

$$F_j = \begin{bmatrix} 1 & & & & & \\ & 1 & & & & \\ & & \ddots & & & \\ & & & c_j - s_j & & \\ & & & s_j & c_j & \\ & & & & & 1 \\ & & & & & & \ddots \\ & & & & & & & 1 \end{bmatrix} \quad \leftarrow \text{row } j+1$$

其中 $c_j = \cos(\theta_j)$, $s_j = \sin(\theta_j)$ 。

假设旋转矩阵 F , $i=1, \dots, j$ 预先作用于 H ,以生成以下维度为 $(j+1) \times j$ 的上三角矩阵:

$$R_j = \begin{bmatrix} x & x & x & x & x & x \\ & x & x & x & x & x \\ & & x & x & x & x \\ & & & x & x & x \\ & & & & x & x \\ & & & & & x \\ 0 & \cdot & \cdot & \cdot & \cdot & 0 \end{bmatrix}$$

字母 x 代表非零元素。在下一步中, H_{j+1} 的最后列和行出现,并被附加到上述矩阵中。为了获得 R_{j+1} ,我们必须先将新列与之前的旋转进行预乘。一旦完成这个操作,我们得到一个 $(j+2) \times (j+1)$ 的矩阵,其形式为

$$\begin{bmatrix} x & x & x & x & x & x & : & x \\ & x & x & x & x & x & : & x \\ & & x & x & x & x & : & x \\ & & & x & x & x & : & x \\ & & & & x & x & : & x \\ & & & & & x & : & x \\ 0 & \cdot & \cdot & \cdot & \cdot & 0 & : & r \\ 0 & \cdot & \cdot & \cdot & \cdot & 0 & : & h \end{bmatrix}$$

上述矩阵的主上 $(j+1) \times j$ 子矩阵即为 R ,而 h 代表 $h_{j+2,j+1}$,该元素不受先前旋转影响。接下来的旋转将通过消除位于 $j+2, j+1$ 位置的元素 h 来实现,具体由旋转 F_{j+1} 定义。

$$C_{j+1} = r / (r^2 + h^2)^{1/2},$$

$$S_{j+1} = -h / (r^2 + h^2)^{1/2}.$$

注意, 连续旋转 F ; 必须同时应用于右侧 βe_1 。

因此, 经过上述过程的 k 步操作后, 我们已获得 H_k 的如下分解形式:

$$Q_k H_k = R$$

其中 Q_k 是 $(k+1) \times (k+1)$ 的旋转矩阵 F 的累积乘积, 而 R_k 是一个 $(k+1) \times k$ 的上三角矩阵, 其最后一行为零。由于 Q_k 是酉矩阵, 我们有:

$$(9) \quad J(y) = \|\beta e_1 - H y\| = \|Q_k [\beta e_1 - H_k y]\| = \|g_k - R y\|,$$

其中 $g_k = Q_k \beta e_1$ 为变换后的右侧。由于 R_k 的末行为零行, 通过求解上三角线性方程组 (该方程组由移除 R_k 末行及 g_k 末分量所得) 可实现(9)的最小化。由此得到 y_k , 再通过线性组合(8)形成近似解 x_k 。

我们先前已论证: 在进行上述分解时, 无需显式计算 x_k , 即可获得近似解 x_k 的残差范数。具体而言, 根据 $J(y)$ 的定义, 该残差范数即为 $J(y_k)$, 而根据公式(9), 其等价于 $\|g_k - R y_k\|$ 。通过 y_k 的构造方式, 该范数即为 g_k 末个分量的绝对值。由此我们证明了以下结论。

命题1. 近似解 x_k 的残差范数等于通过将 βe_1 与将 H_k 转换为上三角矩阵的 k 次连续旋转相乘所得到的右侧 g_k 的第 $(k+1)$ 个分量。

因此, 由于 g_k 在每一步都会更新, QR分解的每一步都能无需额外成本地获得残差范数。这在算法的实际实现中非常有用, 因为它既能避免不必要的迭代, 又可省去显式求得 x_k 所需的额外计算。

接下来我们将详细说明 GMRES 算法最后一步的高效实现方法。若能证明残差向量可由Arnoldi向量 $V_1, \dots, U_m$ 与 $A v_m$ 的组合获得, 则在完成第 m 步后便无需继续计算 v_{m+1} 。值得注意的是, 计算 $m+1$ 及其范数需要进行 $(2m+1)N$ 次乘法运算, 因此省去这部分计算可显著降低计算成本。假设前 $m-1$ 个Arnoldi步骤已完成, 即矩阵 H 的前 $m-1$ 列及前 m 个向量 $v_1, \dots, v_m$ 均已获取。由于我们不会在每一步都对 v_i 进行归一化处理, 因此无法直接获得 v_i 的具体向量形式, 而只能表示为 $w_i = \mu_i D$, 其中 μ_i 为已知的缩放系数。

要计算 x_m , 我们只需要矩阵 H 和向量 $V_1, \dots, U_m$ 。由于向量 v_i ($i=1, \dots, m$) 已知, 只需计算系数 $h_{\{m, i\}}$ ($i=1, \dots, m+1$)。注意到 $h_{\{m, i\}} = (A v_m, v_i)$, 对于 $i \leq m$, 这些前 m 个系数可按如下方式获得:

1. 计算 $A v_m$,

2. 计算 m 个内积 $(A v_m, v_i)$, $i=1, \dots, m$ 。

显然, 上述计算必须使用缩放系数 μ_i ; , 因为 v_i , $i=1, \dots, m$ 仅能表示为 $w_i = \mu_i D$; , 其中 $\mu_i = \|w_i\|$ 。这决定了 H_m 矩阵除元素 $h_{m+1, m}$ 外的第 m 列。我们希望在无需计算 w_{m+1} 的情况下求得该系数。根据定义及 v_i 的正交性

$$(10) \quad h_{m+1, m}^2 = \left\| A v_m - \sum_{i=1}^m h_{i, m} v_i \right\|^2 = \|A v_m\|^2 - \sum_{i=1}^m h_{i, m}^2.$$

因此, 最后一个系数可由 h_i , m 's, $i=1, \dots, m$ 及 $A v_m$ 的范数得出

现将展示如何根据 v_i ($i=1, \dots, m$) 和 $A v_m$ 计算残差向量 $r_m = f - A x_m$ 。该计算仅在重启时必要。根据公式(6), 残差向量可表示为

$$(11) \quad r_m = V m + l [\beta e_1 - H m y_m].$$

若将 t 定义为 $[t_1, t_2, \dots, t_{m+1}] = \beta e_1 - H m y_m$, 则

$$\begin{aligned} r_m &= \left(\sum_{i=1}^m t_i v_i \right) + t_{m+1} v_{m+1} = \left(\sum_{i=1}^m t_i v_i \right) + t_{m+1} \frac{1}{h_{m+1,m}} \left[A v_m - \sum_{i=1}^m h_{i,m} v_i \right] \\ &= \frac{t_{m+1}}{h_{m+1,m}} A v_m + \sum_{i=1}^m (t_i - t_{m+1} h_{i,m} / h_{m+1,m}) v_i. \end{aligned}$$

可以预见, 当 m 较大时, 基于向量 v_i 正交性 (公式10) 的 $h_{m+1,m}$ 替代表达式可能失真[11]。此外, 在重启 GMRES 中, 通过公式11计算 r_m 可能比直接使用 $r_m = f - A x_m$ 更耗时。因此, 当 m 较大时, 不建议采用上述实现方式。

3.3. 与其他方法的对比分析。根据前文对 GMRES 算法的描述, 目前尚无法明确该算法是否比 GCR 或 orthodir 更有效。我们来具体分析这三种方法的计算成本。用 NZ 表示矩阵 A 的非零元素数量。我们将评估 GMRES 算法计算近似解 x_k 的计算成本。虽然存在多种实现方式, 但本文将采用前文所述的实现方案。若忽略计算解 y_k 的成本 (该解是规模为 k 的最小二乘问题的解, 其中 k 通常远小于 N), 那么 GMRES 算法计算 x_k 的总成本可分解为两部分:

- 计算 Arnoldi 向量 v_{j+1} (其中 $j=1, 2, \dots, k$)。该循环的第 j 步需要 $(2j+1)N + NZ$ 次乘法运算, 假设向量 v_j 未进行归一化处理, 仅计算并保存其范数。最后一步仅需 $(k+1)N$ 次乘法运算, 而非常规的 $(2k+1)N$ 次——如前一节所示, 这比常规成本节省了 kN 次乘法。因此, 该部分的总乘法次数约为 $k(k+2)N + kNZ - kN = k(k+1)N + kNZ$ 。

- 在步骤3中形成近似解 $x_0 + V_k y_k$ 需要进行 kN 次乘法运算。

因此, GMRES 的 k 个步骤需要 $k(k+2)N + kNZ$ 次乘法运算。将总步数 k 除以 k 后, 我们发现每个步骤平均需要 $(k+2)N + NZ$ 次乘法。文献[5]表明, GCR 和 orthodir 算法在生成相同近似值 x_k 时, 每个步骤平均需要 $2(3k+5)N + NZ$ 次乘法。因此, 采用上述实现方式时, GMRES 的计算成本始终低于 GCR 或 orthodir。当 k 值较大时, 节省的计算量将接近3。

上述比较针对的是未重启的 GMRES 算法。需要说明的是, 文献[5]中 GCR 和 orthodir 重启版本的符号表示与我们的略有不同: GCR(m) 的每个内循环包含 $m+1$ 个步骤, 而 GMRES (m) 仅包含 m 个步骤。因此 GMRES (m) 在数学上等价于 GCR($m-1$)。当重启 GMRES 时, 我们需要获取完成 m 个步骤后的残差向量。该残差向量可通过显式表达式 $f - A x_m$ 获得, 或如后文所述, 作为 $A v_m$ 与 v_i ($i=1, \dots, m$) 的线性组合。假设

对于后者，我们将执行 $(m+1)N$ 次额外乘法运算。这会使每步平均成本从 $(1+1/m)N$ 增加到 $(m+3+1/m)N+NZ$ 。重启后的GCR和orthodir算法对应的每步成本为 $2(3m+5)N+NZ$ 。因此当 $m>1$ 时，GMRES (m)比GCR(m-1)更具成本效益。需要说明的是，上述GCR(m-1)和orthodir(m-1)的运算次数统计未包含残差向量范数的计算——这是停止准则中必需的步骤，而 GMRES 我们已证明该范数在每一步均可免费获取。这一发现表明，当 $m=1$ 时，两种算法实际上需要相同数量的运算。

对于 GMRES (m)，显然我们只需存储 v' 、近似解以及 Av' 的向量，这意味着需要 $(m+2)N$ 个存储位置。当 m 较大时，这几乎占用了GCR和orthodir所需 $(2m+1)N$ 存储空间的一半。成本对比总结如下表所示，其中GCR(m-1)和 GMRES (m)分别是GCR和 GMRES 的重启版本，每个内循环使用 m 步。需注意orthodir(m-1)的操作次数与GCR(m-1)完全相同[5]。

表1

方法	乘法	存储
GCR (m-1)	$[(3m+5)/2])N+NZ$	$(2m+1)N$
GMRES (m)	$(m+3+1/m)N+NZ$	$(m+2)N$

3.4. GMRES 的理论基础。在评估迭代算法时，一个常见问题是它们是否会出现崩溃。如引言所述，当矩阵A不是正实数（即其对称部分不是正定矩阵）时，GCR算法可能失效。本节将证明，无论矩阵A是否为正定矩阵，GMRES 算法都不会崩溃。

首先，我们假设前 m 个Arnoldi向量可以构造。当 $h_{j+1j}=0, j=1,2, \cdots, m$ 时，这一假设成立。实际上，若 $h_{j+2j+1}=0$ ，则通过上述算法获得的 R_{j+1} 的对角元素 Y_{j+1j+1} 满足：

$$r_{j+1,j+1}=(c_{j+1}r-s_{j+1}h_{j+2,j+1})=(r^2+h_{j+2,j+1}^2)^{1/2}>0.$$

因此， R_{m+1} 的对角元素不为零，故最小二乘问题(9)始终可求解，由此证明该算法不会失效。 $h_{j+1j}\neq 0, j=1, \cdots, m$.

因此唯一可能的潜在困难在于：在Arnoldi过程中，我们可能会遇到一个元素 h_{j+1j} 等于零的情况。假设这种情况确实发生在第 j 步。由于 $h_{j+1j}=0$ ，此时无法构造向量 v_{j+1} 。然而，根据Arnoldi算法可以轻易看出，我们满足关系式 $AV_j=V_{j+1}H_j$ ，这意味着由 V_j 张成的子空间 K_j 保持不变。需要注意的是，如果矩阵A是非奇异的，那么其谱包含在A谱中的子空间H也必定是非奇异的。此时第 j 步的二次型(5)将变为

$$J(y)=\|\beta v_l-AV_jy\|=\|\beta v_l-V_{j+1}H_jy\|=\|V_j[Be_l-H_jy]\|=\|Be_l-H_jy\|。$$

由于H是非奇异的，上述函数在 $y=H^{-1}\beta e_l$ 时为最小值，且对应的最小范数为零，即解 x 是精确的。

为证明逆命题同样成立，假设 x 是精确解，且 $x_{i-1}=0, i=1,2, \cdots, j-1$ 不满足 $r_{i-1}=0$ ，但 $r_i=0 (i=0,1, \cdots, j-1)$ 。此时 $r_{j-1}=0$ ，根据命题1可知残差范数即为 $s_j e_{j-1}^T g_{j-1}$ ，i.e.

由于前一个残差范数不为零, 因此必须有 $s=0$, 这意味着 $h+1j=0$, 即算法失效且 $0j+1=0$, 从而证明了该结果。

此外, 可以证明 $j+1=0$ 且 $i=0$ $i=1, 2, \dots, j$ 等价于初始残余向量 $ro=v_1$ 的极小多项式的次数等于 j 。实际上假设 v_1 的极小多项式的次数为 j 。这意味着存在一个次数为 j 的多项式 p_j 使得 $p_j(A)v_1=0$, 且 p_j 是满足此条件的最低次数多项式。因此 $K_{j+1}=\text{span}\{v_1, Av_1, \dots, A^j v_1\}$ 等于 K 。故向量 $j+1$ 作为 K 的成员, 且 $+1=K$ 且与 K 正交, 必然是零向量。此外, 若 $i=0$ 对 $i \leq j$, 则存在一个次数为 i 的多项式 p_i 使得 $p_i(A)v_1=0$, 这与 p_i 的极小性相矛盾。

为证明逆命题, 假设 $\hat{v}_{j+1}=0$ 且 $i=0$ $i=1, 2, \dots, j$ 。那么存在一个次数为 j 的多项式 p_j 使得 $p_j(A)v_1=0$ 。此外, p_j 是满足此条件的最低次数多项式, 否则根据本证明的第一部分, 对于某个 $i < j$, 我们会有 $D_{i+1}=0$, 这与假设矛盾。

命题2. 步骤 j 中由 GMRES 产生的解 x 是精确的当且仅当以下四个等价条件成立:

- (1) 该算法在第 j 步失效。
- (2) $O_{j+1}=0$ 。
- (3) $h_{j+1j}=0$ 。
- (4) 初始残余向量 ro 的极小多项式的次数等于 j 。

在 Lanczos 算法的语境中, 这种不常见的崩溃有时被称为“幸运”崩溃。由于 v_1 的极小多项式的次数对于 N 维问题不能超过 N , 因此可以立即得出一个推论。

推论3. 对于 $N \times N$ 规模的问题, GMRES 最多需要 N 步即可完成。

命题2的一个重要推论是: 重启算法 GMRES (m) 不会失效。因此, 如果 GMRES (m) 始终收敛, 它将构成一个非常可靠的算法。但遗憾的是, 实际情况并非总是如此——存在某些情形下, 算法产生的残差范数虽非递增, 却无法收敛至零。文献[5]已证明, 当矩阵 A 为正定矩阵时, GCR($m-1$) 方法具有收敛性, 因此 GMRES (m) 同样适用这一结论。但构造反例表明, 该结论并不适用于不定问题: 若矩阵 A 的对称部分非正定, 该方法可能无法收敛。事实上, 我们可以证明重启 GMRES 法可能达到稳态。以问题 $Ax=f$ 为例, 考虑 GMRES (1) 的情形:

$$A = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}, \quad f = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad x_0 = 0,$$

我们在引言中考虑了这个问题。近似解 x_1 使残差范数 $\|f-Az\|$ 最小化, 其中 z 是一个形式为 $z=af$ 的向量。很容易看出 $x_1=0$ 。因此该算法将提供一个平稳序列。注意这与崩溃问题无关。事实上 GMRES 将分两步产生解, 但 GMRES (1) 永远不会。

由于该方法在每一步都对残差范数进行最小化, 因此显然其非增性。直观上, 当 m 足够大时, 残差范数的缩减幅度将足够小, 从而确保收敛性。因此我们预期 GMRES (m) 在 m 足够大时会收敛。但需注意, 最终

当 $m=N$ 时, 结果是平凡的, 即该方法一步收敛。因此, 我们不会尝试证明该方法 GMRES (m) 对足够大的 m 收敛。另一方面, 若 A 是近似正定矩阵 (即当其左半平面特征值较少时), 则无需 m 过大即可实现收敛, 这一点很有用。

为分析这种收敛性, 我们令 P_m 为所有次数 $\leq m$ 的多项式空间, 并令 σ 表示矩阵 A 的谱。以下结果在[5]中针对GCR算法被确立, 是其最优性性质的简单推论。

命题4. 假设 A 可对角化, 即 $A = XDX^{-1}$, 并令

$$(12) \quad \varepsilon^{(m)} = \min_{p \in P_m, p(0)=1} \max_{\lambda_i \in \sigma} |p(\lambda_i)|.$$

随后在第 m 步 GMRES 中给出的残差范数满足

$$\|X\| \|X^{-1}\| \varepsilon^{(m)} \leq \|r_m\|,$$

其中 $\kappa(X) = \|X\| \|X^{-1}\|$ 。

当 A 为具有对称部分 M 的正实数时, 可由命题推导出以下误差界, 参见[5]:

$$\|r_m\| \leq [1 - \alpha/\beta]^{m/2} \|r_0\|,$$

其中 $\alpha = (\lambda_{\min}(M))^2$, $\beta = \lambda_{\max}(ATA)$ 。这证明了当 A 为正实数时, GMRES (m) 对所有 m 都收敛[5]。

当 A 不为正实数时, 上述结果不再成立, 但我们可以为 $\varepsilon^{(m)}$ 建立以下显式上界。

定理5. 假设矩阵 A 有 ν 个特征值 $\lambda_1, \lambda_2, \dots, \lambda_\nu$, 其实部非负, 且其余特征值围成一个以 C 为中心、半径为 R 的圆, 其中 $C > 0$ 且 $R > 0$ 。

$$(13) \quad \varepsilon^{(m)} \leq \left[\frac{R}{C} \right]^{m-\nu} \max_{j=\nu+1, N} \prod_{i=1}^{\nu} \frac{|\lambda_i - \lambda_j|}{|\lambda_i|} \leq \left[\frac{D}{d} \right]^\nu \left[\frac{R}{C} \right]^{m-\nu}$$

在哪里

$$D = \max_{i=1, \nu, j=\nu+1, N} |\lambda_i - \lambda_j| \quad \text{和} \quad d = \min_{i=1, \nu} |\lambda_i|.$$

证明。考虑由 $p(z) = r(z)q(z)$ 定义的特定多项式类, 其中 $r(z) = (1-z/\lambda_1)(1-z/\lambda_2)\cdots(1-z/\lambda_\nu)$, 且 $q(z)$ 是任意次数不超过 $m-\nu$ 的多项式, 满足 $q(0)=1$ 。显然, 由于 $p(0)=1$ 且 $p(\lambda_i) = 0$ ($i=1, \dots, \nu$), 我们有

$$\varepsilon^{(m)} \leq \max_{j=\nu+1, N} |p(\lambda_j)| \leq \max_{j=\nu+1, N} |r(\lambda_j)| \max_{j=\nu+1, N} |q(\lambda_j)|.$$

可以明显看出

$$\max_{j=\nu+1, N} |r(\lambda_j)| = \max_{j=\nu+1, N} \prod_{i=1}^{\nu} \frac{|\lambda_i - \lambda_j|}{|\lambda_i|} \leq (D/d)^\nu.$$

此外, 根据极大值原理, 对于 $z \in \{\lambda_j\}_{j=\nu+1, N}$, $|q(z)|$ 的最大值不大于该集合所围圆周上的最大值。取多项式 $q(z) = [(C-z)/C]$, 其在圆周上的最大模为 $(R/C)^m$, 即可得到所需结果。□

Chandra[3]对对称不定矩阵的情况也得到了类似的结果。需要注意的是, 当矩阵 A 的所有特征值均为实数时, 乘积项的最大值为

不等式(13)的第二部分满足

$$\max_{j=\nu+1, N} \prod_{i=1}^{\nu} \frac{|\lambda_i - \lambda_j|}{|\lambda_i|} = \prod_{i=1}^{\nu} \frac{|\lambda_i - \lambda_N|}{|\lambda_i|}$$

其中 λ_N 是矩阵A的最大特征值。上述定理的一个简单推论如下。

推论6. 在命题4和定理5的假设下, GMRES (m)对于任意初始向量 x_0 收敛, 如果

$$m > \nu \operatorname{Log} \left[\frac{DC}{dR} \kappa(X)^{1/\nu} \right] / \operatorname{Log} \left[\frac{C}{R} \right].$$

需要说明几点。首先, 总体而言, 上界(13)可能并不精确, 因此实际收敛所需的 m 值可能远小于理论预测值。其次, 确保收敛的最小 m 值仅与特征值分布和矩阵X的条件数相关, 尤其与问题规模N无关。第三, 极有可能出现最小 m 值大于N的情况, 此时推论提供的信息将变得无关紧要, 因为当 $m=N$ 时该方法已实现精确收敛。

4.数值实验。本节报告了若干数值实验, 用于比较 GMRES 与其他共轭梯度类方法的性能。测试在VAX-11/780计算机上使用双精度进行, 其单位舍入值接近 6.93×10^{-18} 。后续测试中采用的 GMRES (k)算法会显式计算每次外层迭代的最后一个向量 $vk+1$, 即未采用第3.2节末尾所述的修改方案。

该测试问题源自H. Elman在其论文[5]中描述的以下偏微分方程的五点离散化:

$$-(bux)x - (cux)x + dux + (du)x + eu, + (eu)y + fu = g \quad \text{在}$$

单位正方形上, 其中

$$b(x,y) = e^{-x}, \quad c(x,y) = e \times d(x,y) = \beta(x+y),$$

$$e(x, y) = \gamma(x+y) \quad f(x,y) = 1./(1+x+y)$$

在边界满足狄利克雷边界条件 $u=0$ 的条件下, 右侧函数 g 的选取使得解已知为 $x e \sin(\pi x) \sin(\pi y)$ 。参数 β 和 γ 可用于调节所得线性系统的对称性程度。需注意, 离散化得到的矩阵A保持为正实数, 且与这些参数无关。

我们将用 n 表示正方形两侧的内部节点数量, 用 $h=1/(n+1)$ 表示网格尺寸。在第一个示例中, 我们取 $n=48$ 、 $\gamma=50$ 和 $\beta=1$, 由此得到一个维度为 $N=2304$ 的矩阵。系统通过右侧应用的 MILU 预处理进行预处理, 即求解 $AM^{-1}(Mx)=f$, 其中 M 是通过A的近似LU分解得到的 A 的近似矩阵(参见[5])。当残差范数减少因子 $e=10^{-6}$ 时, 该过程立即停止。下图比较了GCR(k)、GMRES (k)和orthomin(k)在某些代表性k值下的结果。

该图表明, orthomin(k)在 $k=1$ 和 $k=5$ 时未收敛。实际上, 我们发现它在 $k=1$ 至5的所有取值范围内均呈现相同的非收敛行为。另一个值得注意的现象是 GMRES (5)




FIG.4.1. $n=48$,MILU 预处理, $\gamma=50$, $\beta=1$ 。




图4.2. $n=18$, MILU 预处理, $\gamma=50$, $\beta=-20$ 。

其表现几乎与GCR(1)相当。需注意，当 $k=5$ 时获得了所有合理 k 值选择中最佳结果，同样地，GCR(1)对应于GCR(k)的最佳性能表现。

需要指出的是,对于中等精度 ($\varepsilon \geq 10^{-2}$), 公式(5)的 GMRES 略优于公式(1)。最后需要说明的是, orthomin在此示例中表现不佳的原因在于预处理后的系统并非正实数。与更简单的 ILU 预处理相比, MILU 预处理似乎更容易出现此类问题。事实上,在此示例中,当使用 ILU 预处理时, orthomin(1)表现非常出色。

在下一测试中,我们选取了 $n=18$, 生成了一个维度较小的矩阵, 其 $N=324$, $\gamma=50$, $\beta=-20$ 。本次实验的主要目的是证明在某些情况下使用较大参数 m 具有重要意义。我们再次采用了 MILU 预处理法, 停止容差设定为 $\varepsilon=10^{-6}$ 。这个案例的处理难度更高: orthomin(k)在 $k=1$ 到 10 的所有取值区间内都发散; GCR(1)、GCR(2)和 GCR(3)及其对应版本 GMRES (k)($k=2,3,4$) 同样出现发散现象。过程 GMRES (k)在 $k=5$ 时开始收敛, 并随着 k 值增大显著改善。当 k 值较大时, 系统性能达到最佳。下图展示了 GMRES (5)、GMRES (20)和 orthomin(10)的测试结果。为直观对比 GMRES (20)与对应版本 GCR(19)的性能提升, 我们还绘制了 GCR(19)的测试结果。值得注意的是, 我们不仅将乘法运算量减少了近 25%, 存储空间也节省了近一半——这对实验至关重要, 因为我们需要在内存中保留 22 个向量, 而 GCR(19)则需要 39 个向量。

参考文献

- [1] W.E.ARNOLDI., 矩阵特征值问题求解中最小化迭代原理, 《应用数学杂志》, 第9卷(1951年), 第17-29页。
- [2] O. 阿克松, 不对称和不一致线性方程组的共轭梯度法, Lin.Alg.Appl., 29(1980), pp. 1-16.
- [3] R. chandra, 《偏微分方程的共轭梯度法》, 博士论文, 计算机科学系, 耶鲁大学, 康涅狄格州纽黑文, 1978年。
- [4] S.C.eisenstat, H.C. ELMAN 与 M.H.schultz 合著的《非对称线性方程组的变分迭代法》, 发表于《SIAM 数值分析杂志》20卷第1983年345-357页。
- [5] H. C. ELMAN, 《大型稀疏非对称线性方程组的迭代方法》, 博士论文, 耶鲁大学计算机科学系, 康涅狄格州纽黑文, 1982年。
- [6] H.C. ELMAN、Y.SAAD和P. SAYLOR, 一种求解非对称线性方程组的混合切比雪夫-克里洛夫子空间算法, 技术报告YALU/DCS/TR-301, 耶鲁大学, 康涅狄格州纽黑文, 1984年。
- [7] W.C.GEAR与Y. SAAD, 《常微分方程代码中线性方程的迭代求解》, 本刊第4卷(1983年), 第583-601页。
- [8] A.L.哈格曼与D.M.杨合著的《应用迭代方法》由学术出版社于1981年在纽约出版。
- [9] K.C. JEA 与D.M.young合著的《非对称化迭代方法的广义共轭梯度加速技术》, 发表于《线性代数与应用》第34卷(1980年), 第159-194页。
- [10] C.C. PAIGE 与M.A.桑德斯合著的《稀疏不定线性方程组的求解》, 发表于《SIAM数值分析杂志》1975年第12卷, 第617-624页。
- [11] B.N.parlett, 对Lanczos算法求解对称线性方程组的新研究, 林肯应用算法, 29(1980), 323-346.
- [12] Y. SAAD, Arnoldi方法在计算大非对称矩阵特征值上的变体, Lin. Alg.Appl., 34(1980), pp. 269-295.
- [13] —, Krylov子空间方法求解大型非对称线性系统, Math. Comput., 37 (1981), 第105-126页。
- [14] —, Krylov子空间方法在求解不定非对称线性系统中的实际应用, 《期刊》第5卷(1984年), 第203-228页。
- [15] G.W.斯图尔特, 《矩阵计算导论》, 学术出版社, 纽约, 1973年。
- [16] P.K.W. vinsome, orthomin, 一种求解稀疏组线性方程组的迭代方法, 见于《第四届油藏模拟研讨会论文集》, 美国石油工程师协会, 1976年, 第149-159页。