



移动阅读

单连璞, 于彩霞, 王彦飞. 物理信息神经网络求解亥姆霍兹方程的配置点采样方法[J]. 煤田地质与勘探, 2025, 53(9): 182–190. doi: 10.12363/issn.1001-1986.25.03.0197
SHAN Lianpu, YU Caixia, WANG Yanfei. A collocation point sampling method for solving the Helmholtz equation using physics-informed neural networks[J]. Coal Geology & Exploration, 2025, 53(9): 182–190. doi: 10.12363/issn.1001-1986.25.03.0197

物理信息神经网络求解亥姆霍兹方程的配置点采样方法

单连璞^{1,2}, 于彩霞¹, 王彦飞^{1,2,*}

1. 中国科学院地质与地球物理研究所 深层油气理论与智能勘探开发重点实验室, 北京 100029;
2. 中国科学院大学 地球与行星科学学院, 北京 100049

摘要: 【背景】地震波场模拟中, 物理信息神经网络(physics-informed neural networks, PINNs) 凭借其无网格求解特性为亥姆霍兹方程(Helmholtz equation) 高效计算开辟了新途径。然而, 在复杂介质模型的亥姆霍兹方程正演中, 传统的均匀网格配置点采样策略无法高效地提供梯度信息, 导致其训练时间长、资源消耗大。【目的和方法】为了提升 PINNs 的正演效率和精度, 并解决动态采样的配置点在震源处异常聚集这一问题, 提出了基于残差分布的混合配置点重采样策略(hybrid residual-based adaptive distribution, RAD-H), 并与 6 种固定采样策略和 4 种动态采样策略进行对比分析。该策略在震源区域采用固定采样确保震源特征捕捉, 在其他区域则实施基于残差分布的自适应重采样(residual-based adaptive distribution, RAD), 保证重采样配置点与目标高残差区域空间采样的一致性。【结果】经数值实验表明: 在均匀介质模型中, RAD-H 策略相较于经典基准方法仅需使用 18.57% 的配置点数量, 却能够使波场 L2 误差降低 3.050%, 同时该策略训练耗时约为 4 192.5 s, 计算效率较经典基准方法提升了 231.74%; 在 Marmousi2 模型中, RAD-H 策略控制与经典基准方法相同量级误差, 使用的配置点数量减少 57.75%。【结论】该策略解决了其他动态采样策略在震源区域采样过密、其他区域采样不足的问题, 显著提升了 PINNs 在含震源正演中的配置点采样效率, 对高效高精度模拟复杂地质模型波场具有启发意义。

关键词: 物理信息神经网络; 亥姆霍兹方程; 正演; 配置点; 自适应

中图分类号: P631 **文献标志码:** A **文章编号:** 1001-1986(2025)09-0182-09

A collocation point sampling method for solving the Helmholtz equation using physics-informed neural networks

SHAN Lianpu^{1,2}, YU Caixia¹, WANG Yanfei^{1,2,*}

1. Key Laboratory of Deep Petroleum Intelligent Exploration and Development, Institute of Geology and Geophysics, Chinese Academy of Sciences, Beijing 100029, China; 2. College of Earth and Planetary Sciences, University of Chinese Academy of Sciences, Beijing 100049, China

Abstract: [Background] In the field of seismic wavefield simulation, physics-informed neural networks (PINNs) have emerged as a new method for efficiently solving the Helmholtz equation due to their characteristic of grid-free computation. However, for the forward modeling of complex medium models using the Helmholtz equation, traditional uniform grid-based methods for collocation point sampling are insufficient to efficiently provide gradient information, leading to prolonged training time and high resource consumption. [Objective and Method] To improve the forward modeling efficiency and accuracy based on PINNs and overcome the anomalous concentration of collocation points in the seismic source during dynamic sampling, this study proposed a hybrid residual-based adaptive distribution (RAD-H) method and

收稿日期: 2025-03-18 接收日期: 2025-05-09

基金项目: 国家重点研发计划(2024YFA1012304); 国家自然科学基金项目(42450232)

第一作者: 单连璞, 1997 年生, 男, 山东青岛人, 博士研究生。E-mail: shanlianpu22@mails.ucas.ac.cn

*通信作者: 王彦飞, 男, 河北张家口人, 博士, 研究员。E-mail: yfwang@mail.iggcas.ac.cn

© Editorial Office of Coal Geology & Exploration. OA under CC BY-NC-ND

then compared this method with six fixed and four dynamic sampling methods. In the RAD-H method, fixed sampling is employed for the seismic source area to ensure the capture of the source features, and residual-based adaptive distribution (RAD) is used for other areas to ensure the consistency between the resampled collocation points and the spatial sampling of the high-residual target area. **[Results]** Numerical experiments indicate that for a homogeneous medium model, the RAD-H method reduced the L2 error of the wavefield by 3.050% using only 18.57% of collocation points compared to the classical baseline method. Moreover, the RAD-H method exhibited a model training time of approximately 4 192.5 s, suggesting an improvement of 231.74% in computational efficiency compared to the classical baseline method. For the Marmousi2 model, the RAD-H strategy remained the error within the same order of magnitude as the classical baseline method while reducing the number of collocation points by 57.75%. **[Conclusions]** The RAD-H method overcomes oversampling for seismic source areas and undersampling for other areas of other dynamic sampling methods, significantly enhancing the sampling efficiency of collocation points of PINNs during the forward modeling involving seismic sources. This study holds significant implications for efficient, high-precision wavefield simulation of complex geological models.

Keywords: physics-informed neural networks (PINNs); Helmholtz equation; forward modeling; collocation point; adaptive distribution

地震波场模拟是地震勘探的核心环节,它不仅为阐释波场传播的动力学机制提供科学依据,更为实现高精度地下介质参数反演提供技术支撑。波动方程求解是模拟过程的基石,其解析解仅存在于均匀介质、规则几何域等理想化场景,面对实际勘探中复杂的地质条件,必须依赖有限差分法或有限元法等数值方法求解。然而,有限差分法在非均匀介质中因网格离散化导致数值频散效应^[1],有限元法因全局矩阵求解导致计算成本高昂^[2]。传统数值方法面临的精度-效率矛盾催生出基于深度学习代理模型的波动方程求解新范式。

物理信息神经网络(PINNs)将偏微分方程求解转化为参数空间优化问题^[3],构建了“数据-物理”双驱动学习框架。该方法以神经网络为函数逼近器,借助自动微分技术精确计算微分算子,同步最小化损失函数的物理约束项与边界(初始)条件损失项,实现对解函数的隐式参数化表征,最终达成无网格条件下高效高精度求解^[4-5]。在地震波场模拟领域,其应用潜力已获得多维度验证:U. Bin Waheed 等^[6]率先将 PINNs 应用于程函方程求解,验证了该方法处理走时问题的可行性。后续学者进一步发展了其在微震定位^[7]和旅行时求取^[8]中的应用。S. Karimpouli 等^[9]基于各向同性介质实现二维波动方程正演模拟;U. Bin Waheed^[10]将该方法进一步拓展至各向异性介质;Song Chao 等^[11-12]则将其应用于亥姆霍兹方程求解。地震反演方面,Xu Yiran 等^[13]在简单非均匀介质中实现速度参数反演,M. Rasht-Behesht 等^[14]将 PINNs 应用于更复杂的非均匀介质的地震反演,二者证实了 PINNs 在速度反演中的理论可行性。

在利用 PINNs 求解亥姆霍兹方程时,频谱偏差与训练成本过高是两大核心挑战^[15]。现有研究虽通过改进激活函数^[11]、引入傅里叶特征编码^[12]等技术途径有效改善了频谱偏差问题,然而训练效率尚未达成关键性

突破。针对大规模高精度正演问题,训练成本受多重因素制约:网络规模(深度、宽度)与问题复杂度呈正相关,多频波场正演需逐频段独立训练网络,配置点采样策略欠优化加剧计算资源消耗。当前研究普遍采用均匀网格化固定配置点采样策略^[11],该策略虽可确保基础精度,但配置点在平滑区域与高梯度区域(如震源附近、介质界面)采用相同密度,大量配置点未贡献有效梯度信息。优化配置点采样策略可显著提升计算效能,Wu Yuanqing 等^[16]在流体力学问题中引入自适应重要性采样策略,在精度无损条件下实现配置点规模缩减 60%,验证了优化采样策略可能突破效率瓶颈。地球物理领域目前缺少对配置点采样策略的研究。

为此,笔者针对 PINNs 解亥姆霍兹方程训练成本高的问题,以及基于残差的动态采样策略在训练过程中配置点异常集中现象,提出基于残差分布的混合配置点重采样策略(hybrid residual-based adaptive distribution, RAD-H),旨在正确捕捉高残差区域,减少采用的配置点数量进而提高计算效率,为地震勘探领域的大规模波场正演提供高性价比数值方案。

1 方法原理

1.1 PINNs 解带有 PML 的亥姆霍兹方程

本研究针对二维频域声波传播问题,其控制方程一般形式为

$$[\nabla^2 + \omega^2 m(\mathbf{X})]u(\mathbf{X}, \omega) = s(\mathbf{X}, \omega) \quad (1)$$

为抑制有限计算域边界反射,引入 PML 修正方程:

$$\frac{\partial}{\partial x} \left(\frac{e_z}{e_x} \frac{\partial u}{\partial x} \right) + \frac{\partial}{\partial z} \left(\frac{e_x}{e_z} \frac{\partial u}{\partial z} \right) + \omega^2 e_x e_z m(\mathbf{X})u(\mathbf{X}, \omega) = s(\mathbf{X}, \omega) \quad (2)$$

其中,复数拉伸因子 $e_x, e_z \in \mathbb{C}$,实部保持波传播特性,虚部引入与频率相关的衰减。

$$e_{x,z} = 1 - i \frac{\sigma_{x,z}}{\omega} \quad (3)$$

σ_x, σ_z 表示阻尼因子:

$$\sigma_{x,z} = \begin{cases} 2\pi a_0 f_0 \left(\frac{L_{x,z}}{L_{PML}} \right)^2 & \text{PML层内} \\ 0 & \text{计算域内} \end{cases} \quad (4)$$

图 1 展示了 PINNs 求解亥姆霍兹方程的基本框架。PINNs 网络架构包括三部分: 输入层 $\mathbf{Y}^{(0)}$, 将空间坐标 $\mathbf{X} = \{x, z\}$ 作为输入数据输入网络, 即配置点; 隐藏层 $\mathbf{Y}^{(\hat{m})}$, 采用固定频率为 ω_0 正弦激活函数, 以缓解频谱偏差; 输出层 $\mathbf{Y}^{(\hat{M})}$, 通过对最后一层隐藏层 $\mathbf{Y}^{(\hat{M}-1)}$ 施加仿射线映射获得, 从而得到复值波场的参数化形式 $u(\mathbf{X}, \omega; \theta) = \mathbf{Y}^{(\hat{M})}$ 。

$$\begin{aligned} \mathbf{Y}^{(0)} &= (x, z) \\ \mathbf{Y}^{(\hat{m})} &= \sin \left[\omega_0 \left(\mathbf{W}^{(\hat{m})} \mathbf{Y}^{(\hat{m}-1)} + \mathbf{b}^{(\hat{m})} \right) \right] \\ \mathbf{Y}^{(\hat{M})} &= \mathbf{W}^{(\hat{M})} \mathbf{Y}^{(\hat{M}-1)} + \mathbf{b}^{(\hat{M})} \end{aligned} \quad (5)$$

网络所有权重矩阵 $\mathbf{W}^{(\hat{m})}$ 与偏置向量 $\mathbf{b}^{(\hat{m})}$ 构成可训练参数集:

$$\theta = \left\{ \mathbf{W}^{(\hat{m})}, \mathbf{b}^{(\hat{m})} \right\}_{1 \leq \hat{m} \leq \hat{M}} \quad (6)$$

由于 PML 通过坐标拉伸将外向波衰减至零, 天然满足辐射边界条件, 因此无需显式添加边界约束项。同

时, 为确保与传统数值方法对比的公平性, 本研究未引入基于监督学习的数据损失项。此时损失函数仅包含方程残差项:

$$\mathcal{L}(\mathbf{X}; \theta) = \frac{1}{N} \sum_{i=1}^N \left| \frac{\partial}{\partial x} \left(A_i \frac{\partial u_i}{\partial x} \right) + \frac{\partial}{\partial z} \left(B_i \frac{\partial u_i}{\partial z} \right) + C_i \omega^2 m_i(\mathbf{X}) u_i(\mathbf{X}, \omega; \theta) - s_i(\mathbf{X}, \omega) \right|^2 \quad (7)$$

网络的训练过程可转化为以下无约束优化问题:

$$\theta^* = \arg \min_{\theta} \mathcal{L}(\mathbf{X}; \theta) \quad (8)$$

在训练过程中, PINNs 常用两阶段优化策略, 对可训练参数集 θ , 梯度下降方向更新迭代; 首先使用 Adam(adaptive moment estimation) 优化器快速逼近全局最优区域, 再由 L-BFGS(limited-memory Broyden-Fletcher-Goldfarb-Shanno) 优化器进行精细调优, 通过最小化损失函数 $\mathcal{L}(\mathbf{X}; \theta)$, 以确定最优参数 θ^* 。

模型训练收敛后, 采用空间加密采样的评估配置点集 Ω_{eval} , 其采样密度为训练集的 10 倍以上, 并基于 L2 误差进行误差分析:

$$\varepsilon = \left\| \hat{u} - u^* \right\|_2 \quad (9)$$

其中, $\hat{u}$ 为神经网络输出的解, u^* 为通过优化 9 点有限差分法^[17] 计算得到的高精度参考解。




图 1 PINNs 求解亥姆霍兹方程的基本框架

Fig.1 Basic architecture for solving the Helmholtz equation using PINNs

1.2 配置点采样策略

作为 PINNs 关键技术之一, 配置点采样策略可分为固定采样与动态采样两类。固定采样在训练前通过确定性规则生成配置点集, 并在训练全周期保持空间分布不变, 其典型方法包括等间距网格采样、拉丁超立方采样以及基于低差异序列准蒙特卡罗方法。在此类基于 PINNs 的波场正演研究中, 等间距均匀网格采样与拉丁超立方采样是配置点采样策略的主流选择。此外, 基于准随机低差异序列的采样方式包括 Sobol 序列^[18]、

Halton 序列^[19] 和 Hammersley 序列^[20]。动态采样在训练过程中迭代调整配置点分布, 除随机重采样外, 可从自适应准则与更新策略 2 个维度进行分类(表 1): 就自适应准则而言, 主要包括基于残差、残差变化率、解梯度以及不确定性的自适应采样策略; 从更新策略视角, 分为增量式与重采样式。

在各类采样策略中, 残差驱动方法的研究最为广泛。其中代表性方法 RAR(residual-based adaptive refinement)^[32] 采用“训练-残差估计-采样优化”的流程: 首先

表 1 动态采样的自适应准则与更新策略部分成果
Table 1 Adaptive criteria and update strategies for dynamic sampling: Partial results

自适应准则	增量式更新策略	重采样式更新策略
随机	文献[21]	文献[22]
问题驱动	文献[13,23-25]	文献[26-27]
残差	文献[28-34]	文献[33,35-36]
残差变化	文献[37]	文献[38]
解的梯度	文献[39]	文献[36]
不确定度		文献[40-42]

生成初始配置点集并开展预训练,随后在加密评估配置点集上计算物理方程损失视为残差估计值,将残差绝对值最大的 K 个评估配置点加入训练配置点集,实现配置点的自适应分布。然而,这种硬阈值机制会导致配置点在高残差区域过度聚集。为此, RAR-D 和 RAD^[33] 可依据概率分布更新配置点,构建与残差成正比的概率密度函数 $p(\boldsymbol{X})$,使残差大的点被选中的概率高,残差较小的点也可能被选,避免配置点过度集中。

$$p(\boldsymbol{X}) \propto \varepsilon(\boldsymbol{X}) \tag{10}$$

上述基于残差动态调整配置点的方式旨在根据训练过程中的实际情况,更加高效地利用配置点信息,从而优化训练效果。

2 数值实验

本研究通过均匀介质模型实验,解析配置点采样策略对亥姆霍兹方程正演精度的影响规律。采用均匀网格采样作为经典基准方法,针对 6 种固定采样策略与 4 种动态策略开展对比实验,重点探究 2 个关键参数:配置点总数(N)和动态更新周期(τ)对 L2 误差的影响。针对基于残差的动态采样中震源区配置点过度聚集现象,本文提出基于残差分布的混合配置点重采样策略(RAD-H),并通过均匀介质模型与 Marmousi2 模型二者验证其有效性。

所有数值实验均基于 PyTorch 框架开发,关键硬件配置详见表 2。为确保实验结果具有统计显著性,每个对照实验均执行 3 次独立重复试验。通过固定随机数生成器设置保证计算可复现性,最终数据以均值±标准差形式呈现。

表 2 训练用的计算机配置
Table 2 Computer configuration for model training

配置类别	设备
操作系统	Windows 11 家庭版
内存	8 GB
CPU	Intel(R) Core(TM) i7-9750H CPU@2.60 GHz 6核
GPU	NVIDIA GeForce RTX 2070 with Max-Q Design
显存	8 GB

2.1 均匀介质模型

均匀介质模型的关键物理参数设置见表 3,采用空间网格数为 101×101 的离散化模型,空间步长为 20 m,震源位于模型几何中心点,并通过 50 层 PML 边界吸收反射波。神经网络采用固定频率 $\omega_0 = 4$ Hz 的正弦激活函数,优化过程首先利用初始学习率为 0.001 的 Adam 优化器进行 50 000 轮次迭代以快速收敛至参数空间的最优区域,随后切换至 L-BFGS 优化器进行 10 000 轮次迭代,利用其二阶收敛特性提升求解精度。

表 3 均匀模型和 Marmousi2 模型参数
Table 3 Parameters for the homogeneous medium and Marmousi2 models

参数	均匀介质模型	Marmousi2模型
模型频率/Hz	4	3
网格尺寸	101×101	371×101
PML网格数	50	50
空间步长/m	20	25
震源位置	(50,50)	(180,10)
子波类型	Ricker	Ricker
子波频率/Hz	8	8
速度/(km·s ⁻¹)	2	变速

针对网络规模超参数优化问题,当前研究尚未形成系统的理论框架,本研究基于网格搜索方法使用等间距均匀网格采样方可对 PINNs 的超参数空间进行搜索:隐藏层数 $l \in \{2, 4, 6, 8\}$ 与神经元数 $n \in \{20, 40, 80\}$,共形成 12 组参数组合(表 4)。当采用浅层架构(2 层),组 1 和组 5 的 L2 误差分别达到 10.230 00±0.049 40 和 5.525 10±2.380 00,表明低维表征空间难以有效捕捉解场的特征;组 9 的神经元为 80, L2 误差显著降至 1.674 20±0.127 00,表明增加宽度可缓解深度不足缺陷。当采用深层架构(大于 6 层)面临收敛挑战:组 3、组 4、组 7、组 8 及组 12 均无法获得有效解,组 10 和组 11 的 L2 误差骤增至 13.034 00±0.003 52 和 13.035 00±0.000 59,揭示网络规模过大会引发优化失效。最终,组 6 以 1.255 90 的最低 L2 误差(标准差±0.003 84)并保持合理的耗时,展现出最优综合性能,将其作为后续的网络规模标准设置。

对于 6 种固定采样策略,以 Song Chao 等^[1]采用 201×201 的等间距均匀网格采样为经典基准方法, L2 误差为 1.255 900±0.003 84,计算总耗时为 13 908 s。实验表明:在 2 500~5 000 配置点区间,所有方法均未实现有效收敛(表 5),表明有限的配置点数量无法提供稳定收敛所需的条件。值得注意的是, Hammersley 方法在 5 000 点时首次出现误差显著下降,其误差为 5.179 50±5.560 00,高标准差表明多次重复训练中仅部分实现收

表 4 均匀介质模型中隐藏层数与神经元数对 L2 误差与训练耗时的影响

Table 4 Effect of the number of hidden layers and neurons on L2 error and training time in a homogeneous medium model

组别	神经元数	隐藏层数	L2误差	Adam耗时/s	L-BFGS耗时/s
组1	20	2	10.230 00±0.049 40	0.037±0.001	0.101±0.001
组2	20	4	1.356 80±0.043 00	0.061±0.001	0.148±0.003
组3	20	6	*	0.084±0.001	0.199±0.004
组4	20	8	*	0.105±0.007	0.235±0.014
组5	40	2	5.525 10±2.380 00	0.041±0.001	0.111±0.002
组6	40	4	1.255 90±0.003 84	0.055±0.007	0.139±0.017
组7	40	6	*	0.088±0.004	0.193±0.022
组8	40	8	*	0.106±0.013	0.251±0.028
组9	80	2	1.674 20±0.127 00	0.042±0.001	0.118±0.003
组10	80	4	13.034 00±0.003 52	0.067±0.001	0.167±0.001
组11	80	6	13.035 00±0.000 59	0.095±0.003	0.227±0.007
组12	80	8	*	0.112±0.015	0.261±0.033

注：*表示训练过程中损失函数未收敛，下同。

敛。当配置点达到 7 500 的临界数量时, Hammersley 方法率先实现 $1.248\ 10\pm0.004\ 09$ 的稳定收敛, 其误差较经典基准方法降低 0.621%。Halton 方法($5.197\ 90\pm5.550\ 00$)与 Sobol 方法($3.730\ 30\pm3.490\ 00$)方法仍未完全收敛。当配置点数增至 10 000 时, Hammersley、Halton 与 Sobol 方法已稳定收敛, 而随机采样及拉丁超立方采样仍无法有效收敛。当配置点数达到 15 000 时,

除拉丁超立方采样外, 其他方法均稳定收敛。Hammersley 方法配置点规模从 2 500 到 7 500 相应的计算耗时缓慢增加(总耗时依次为 3 187、3 232、3 372 s), 但随着点数由 10 000 增至 15 000 耗时非线性激增($5\ 868\ s$ 增至 $9\ 137\ s$)。综上, 采用 7 500 点 Hammersley 采样策略以最低成本实现可靠收敛(图 2), 为精度-效率均衡的最优选择。

表 5 均匀介质模型中固定采样策略与配置点对 L2 误差影响

Table 5 Effects of a fixed sampling strategy and the number of collocation points on L2 error in a homogeneous medium model

配置点数	L2误差				
	随机采样	拉丁超立方采样	Halton序列	Sobol序列	Hammersley序列
2 500	13.041 00±0.004 47	13.041 00±0.002 42	13.035 00±0.006 37	13.035 00±0.002 71	13.038 00±0.002 59
5 000	13.038 00±0.004 19	13.032 00±0.006 14	13.041 00±0.003 03	13.043 00±0.003 35	5.179 50±5.560 00
7 500	13.039 00±0.002 74	13.042 00±0.003 99	5.197 90±5.550 00	3.730 30±3.490 00	1.248 10±0.004 09
10 000	11.597 00±2.040 00	13.041 00±0.004 11	1.262 60±0.000 98	1.268 80±0.015 20	1.247 20±0.007 68
15 000	1.244 00±0.014 60	5.175 40±5.560 00	1.255 10±0.004 25	1.234 40±0.000 38	1.231 50±0.007 28

为避免以牺牲计算效率为代价研究动态采用样, 选择 7 500 点的 Hammersley 固定采样作为初始采样策略, 并在此基础上进一步提升精度。后续的对比中, 将该策略记为新基准方法。

动态采样策略实施流程如下: 预训练阶段采用 Hammersley 序列生成 7 500 个初始配置点, 经 25 000 轮次 Adam 优化转为总计 25 000 轮次 L-BFGS 精细训练后; 每当 L-BFGS 的训练周期达到 $\tau\in\{500, 1\ 000, 2\ 500, 5\ 000\}$ 时触发配置点动态更新机制——通过随机重采样或 RAD 方法实现全局重采样, 通过 RAR 或 RAR-D 方法进行增量式采样。

由表 6 可知, 对于随机重采样, 当 $\tau=500$ 时, 因随

机扰动导致样本未收敛; 当 $\tau=2\ 500$ 时, 随机重采样方法误差为 $1.246\ 40\pm0.012\ 10$ 优于经典基准方法, 证明通过调整配置点采样方式正演精度仍有提升空间。但随着周期延长至 $\tau=5\ 000$, 误差反弹至 $1.293\ 80\pm0.042\ 30$ 。自适应方法中, RAR-D 方法与 RAD 方法的最优精度分别达到 $1.255\ 30\pm0.002\ 03$ 和 $1.249\ 70\pm0.004\ 02$, 上述动态采样策略效果并不理想, 部分结果优于经典基准方法, 但均未超过新基准方法。

以更新周期 $\tau=1\ 000$ 为例(其他周期呈现相似特征), 图 3a 显示评估配置点集上剔除损失极端高损失点后的残差分布特征, 其中高损失区域本应是基于残差的动态采样策略的目标采样区域, 然而 RAR、RAR-D 及




图 2 均匀介质模型正演结果及 L2 误差
Fig.2 Forward modeling results and L2 errors of the homogeneous medium model

表 6 均匀介质模型中动态采样方式与更新周期对 L2 误差影响
Table 6 Effects of a dynamic sampling strategy and update period on L2 error in a homogeneous medium model

更新周期	L2误差				
	随机重采样	RAR	RAR-D	RAD	RAD-H
500	*	1.267 40±0.013 30	1.460 20±0.007 82	1.258 50±0.005 05	1.246 20±0. 004 68
1 000	1.302 80±0.029 90	3.834 80±3.580 00	1.254 70±0.002 63	1.250 40±0.008 83	1.225 70±0.007 81
2 500	1.246 40±0.012 10	1.294 40±0.031 20	1.255 20±0.018 30	1.255 10±0.017 60	1.217 60±0.003 78
5 000	1.293 80±0.042 30	1.313 90±0.042 50	1.255 30±0.002 03	1.249 70±0.004 02	1.220 30±0.004 58

RAD 策略更新的配置点均显著集中于震源邻域。具体表现为: RAR 策略(图 3b)新增配置点完全集中于震源近场(距震源距离 < 0.05λ); RAR-D 策略新增配置点(图 3c)与高残差目标采样区空间分布一致性差; RAD 策略(图 3d)71.4%的重采样点集中于震源近场。该偏差源于震源近场振幅绝对值显著偏高,致使评估后的误差分布中形成极端高误差区域,在高残差的驱动下,更新后的配置点向震源区域聚集,导致动态采样策略的精度未能超越新基准方法。

为此,本研究提出基于残差分布的混合配置点重采样策略(RAD-H),在震源区域实施固定均匀网格采样,同时其他区域应用 RAD 采样策略屏蔽震源干扰,融合两种方法形成 RAD-H 方法。对比图 3a 与图 3e,该方法使配置点分布与目标损失分布之间的空间一致性得到显著改善。由表 6 可知,RAD-H 仅使用经典基准方法约 18.57%的配置点在 $\tau = 2\,500$ 时实现 $1.217\,60 \pm 0.003\,78$ 的 L2 误差,95%的置信区间为 [1.208 20, 1.227 00],这说明该方法在重复实验中具有高度一致性,即使考虑随机性波动,误差的上限值 1.227 00 仍显著优于经典基准方法($1.255\,90 \pm 0.003\,84$)和新基准方法($1.248\,10 \pm 0.004\,09$)。该方法误差较经典基准方法降低 3.050%,较新基准方法降低 2.444%,虽然下降幅度

不大,但以相同的配置点规模突破了新基准方法的误差阈值。随机重采样、RAR、RAR-D 和 RAD 方法共计进行了 48 次计算机模拟(4 种方法×4 种周期×3 次重复)。模拟结果部分优于经典基准方法,无一优于新基准方法,而 RAD-H 方法更新周期为 1 000、2 500 和 5 000 的 9 次实验(3 种周期×3 次重复)均稳定超越上述 2 种方法。该策略在 $\tau = 2\,500$ 时训练耗时为 4 192.5 s,计算效率相较于基准方法上升了 231.74%。综上所述,该策略能够在较高的效率下有效提升亥姆霍兹方程正演的精度与稳定性。

2.2 Marmousi2 模型

针对含 PML 边界的 Marmousi2 模型亥姆霍兹方程正演问题(主频 3 Hz,关键参数见表 2),构建了隐藏层为 8×神经元 60 的全连接神经网络架构,采用固定频率 4 Hz 的正弦激活函数。优化器实施 Adam-LBFGS 两阶段策略:首阶段执行 100 000 轮 Adam 训练,随后进行 50 000 轮 L-BFGS 训练。

实验表明,RAR、RAR-D、RAD 的 L2 误差分别为 58.0、57.2 和 55.8,相较于 RAD-H 分别高出 134.8%、131.6%、125.9%,以上误差对比清晰展现了 RAD-H 具有精度优势。相较于经典基准方法,所提 RAD-H 策略在同等精度水平(24.3)下,所需配置点数缩减至 40 000 个(降幅达 57.75%)。该实验证明,RAD-H 方法(图 4)




图 3 目标区域实际损失分布与 4 种动态采样新增/重采样配置点分布

Fig.3 Actual loss distribution in the target region and distributions of newly added/resampled collocation points for four dynamic sampling strategies

通过动态采样策略减少冗余计算,在复杂介质模型建模中展现出显著的加速收敛特性。




图 4 Marmousi2 模型正演结果

Fig.4 Forward modeling results of the Marmousi2 model

3 结论

(1) 针对地球物理领域亥姆霍兹方程正问题,提出

了一种 PINNs 的基于残差分布的混合配置点重采样策略。

(2) 该方法将固定采样与动态采样相结合,在 Hammersley 序列采样的预训练基础上,通过周期性残差估计与配置点重采样有效捕捉高残差区域,在迭代训练中充分利用配置点提供的信息,有效降低了收敛所需的配置点数量并且提高了预测解精度。

(3) 在均匀介质模型上,新方法仅使用经典基准方法的 18.57% 配置点数,同时误差降低 3.050%。在 Marmousi2 模型上,该方法与经典基准方法保持相同的误差精度使用的配置点数减少 57.75%,为 PINNs 求解更复杂模型提供新思路。

符号注释:

a_0 为阻尼因子的经验系数,本次取值 0.5; $A = e_x^{-1}e_z$, $B = e_x e_z^{-1}$, $C = e_x e_z$ 为复数拉伸因子的参数组合; e_x, e_z 为复数拉伸因子; f_0 为源函数主频, Hz; i 为配置点索引; L_x 为内部点到 PML 界面的水平距离, m; L_z 为内部点到 RML 界面的垂直距离, m; L_{PML} 为 PML 层的厚度, m; $\mathcal{L}(X; \theta)$ 为损失函数; $m(X)$ 为介质平方慢度, s^2/m^2 ; $\hat{m}$ 为神经网络第 $\hat{m}$ 层; $\hat{M}$ 为神经网络隐藏层数; N 为神经网络采样的配置点数; $p(X)$ 为基于残差动态采样策略的概率密度函数; $s(X)$ 为震源项; $u(X)$ 为复值位移场; $\hat{u}$ 为神经网络输出的解, u^* 为通过优化 9 点有限差分法计算得到的高精度参考解; $\mathbf{W}^{(\hat{m})}$ 和 $\mathbf{b}^{(\hat{m})}$ 分别为第 $\hat{m}$ 层中神经元的权重与偏置; $\mathbf{X} = \{x, z\}$ 为空间位置, x, z 分别对应水平与深度方向, m; $\mathbf{Y}^{(0)}$ 为输入层的输入特征; $\mathbf{Y}^{(\hat{m})}$ 为第 $\hat{m}$ 层输出特征 $\hat{m} = 1, 2, \dots, \hat{M} - 1$; $\mathbf{Y}^{(\hat{m}-1)}$ 为来自 $\hat{m} - 1$ 层输入特征; $\mathbf{Y}^{(\hat{M})}$ 为神经网络输出的复值解; ε 为 L2 误差; θ 为可训练参数; θ^* 为最优参数; λ 为波长, m; σ_x, σ_z 为阻尼因子; τ 为动态采样策略配置点更新周期; Ω_{eval} 为评估配置点集; ω 为角频率, rad/s; ω_0 为固定激活正弦函数频率, rad/s; ∇^2 为拉普拉斯算子; $\|\cdot\|_2$ 为 L2 范数。

利益冲突声明/Conflict of Interests

所有作者声明不存在利益冲突。

All authors disclose no relevant conflict of interests.

参考文献(References)

- [1] 方修政, 姚刚, 钮凤林, 等. 波场模拟有限差分参数优化选取[J]. 地球物理学报, 2023, 66(6): 2520–2533.
FANG Xiuzheng, YAO Gang, NIU Fenglin, et al. Estimating optimal parameters of finite-difference scheme for wavefield modeling[J]. Chinese Journal of Geophysics, 2023, 66(6): 2520–2533.
- [2] 苏波, 李怀良, 刘少林, 等. 修正辛格式有限元法的地震波场模拟[J]. 地球物理学报, 2019, 62(4): 1440–1452.

- SU Bo, LI Huailiang, LIU Shaolin, et al. Modified symplectic scheme with finite element method for seismic wavefield modeling[J]. Chinese Journal of Geophysics, 2019, 62(4): 1440–1452.
- [3] RAISSI M, PERDIKARIS P, KARNIADAKIS G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. Journal of Computational Physics, 2019, 378: 686–707.
- [4] 李野, 陈松灿. 基于物理信息的神经网络: 最新进展与展望[J]. 计算机科学, 2022, 49(4): 254–262.
- LI Ye, CHEN Songcan. Physics-informed neural networks: Recent advances and prospects[J]. Computer Science, 2022, 49(4): 254–262.
- [5] 李航, 孙宇航, 李佳慧, 等. 基于波动方程的地震波数值模拟研究综述[J]. 吉林大学学报(地球科学版), 2025, 55(2): 627–645.
- LI Hang, SUN Yuhang, LI Jiahui, et al. A comprehensive review of numerical simulation of seismic waves based on wave equation[J]. Journal of Jilin University (Earth Science Edition), 2025, 55(2): 627–645.
- [6] BIN WAHEED U, HAGHIGHAT E, ALKHALIFAH T, et al. PINNeik: Eikonal solution using physics-informed neural networks[J]. Computers & Geosciences, 2021, 155: 104833.
- [7] 潘登, 唐杰, 范忠豪, 等. 基于自适应损失均衡梯度增强的物理信息神经网络微地震定位[J]. 石油地球物理勘探, 2025, 60(3): 630–642.
- PAN Deng, TANG Jie, FAN Zhonghao, et al. Adaptive-loss-weighting gradient-enhanced physics-informed neural network for microseismic localization[J]. Oil Geophysical Prospecting, 2025, 60(3): 630–642.
- [8] 都国宁, 谭军, 宋鹏, 等. 基于物理信息驱动神经网络的三维初至波旅行时计算方法[J]. 石油地球物理勘探, 2023, 58(1): 9–20.
- DU Guoning, TAN Jun, SONG Peng, et al. 3D travelttime calculation of first arrival wave using physics-informed neural network[J]. Oil Geophysical Prospecting, 2023, 58(1): 9–20.
- [9] KARIMPOULI S, TAHMASEBI P. Physics informed machine learning: Seismic wave equation[J]. Geoscience Frontiers, 2020, 11(6): 1993–2001.
- [10] BIN WAHEED U. Kronecker neural networks overcome spectral bias for PINN-based wavefield computation[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 8029805.
- [11] SONG Chao, ALKHALIFAH T, BIN WAHEED U. A versatile framework to solve the Helmholtz equation using physics-informed neural networks[J]. Geophysical Journal International, 2022, 228(3): 1750–1762.
- [12] SONG Chao, WANG Yanghua. Simulating seismic multifrequency wavefields with the Fourier feature physics-informed neural network[J]. Geophysical Journal International, 2023, 232(3): 1503–1514.
- [13] XU Yiran, LI Jingye, CHEN Xiaohong. Physics informed neural networks for velocity inversion[C]//SEG International Exposition and Annual Meeting. San Antonio: Society of Exploration Geophysicists, 2019: SEG–2019–3216823.
- [14] RASHT-BEHESHT M, HUBER C, SHUKLA K, et al. Physics-informed neural networks (PINNs) for wave propagation and full waveform inversions[J]. Journal of Geophysical Research: Solid Earth, 2022, 127(5): e2021JB023120.
- [15] 邹婧博, 刘财, 赵鹏飞. 地震波正演问题的物理信息神经网络算法研究进展[J]. 地球物理学进展, 2023, 38(1): 430–448.
- ZOU Jingbo, LIU Cai, ZHAO Pengfei. Research progress of physics-informed neural network in seismic wave modeling[J]. Progress in Geophysics, 2023, 38(1): 430–448.
- [16] WU Yuanqing, SUN Shuyu. Enhancing the accuracy of physics-informed neural network surrogates in flash calculations using sparse grid guidance[J]. Fluid Phase Equilibria, 2024, 578: 113984.
- [17] JO C H, SHIN C, SUH J H. An optimal 9-point, finite-difference, frequency-space, 2-D scalar wave extrapolator[J]. Geophysics, 1996, 61(2): 529–537.
- [18] SOBOL I M. On the distribution of points in a cube and the approximate evaluation of integrals[J]. USSR Computational Mathematics and Mathematical Physics, 1967, 7(4): 86–112.
- [19] HALTON J H. On the efficiency of certain quasi-random sequences of points in evaluating multi-dimensional integrals[J]. Numerische Mathematik, 1960, 2(1): 84–90.
- [20] HAMMERSLEY J M, HANDSCOMB D C. Monte carlo methods[M]. London: Methuen & Wiley, 1964.
- [21] WANG G, FANG Q, WANG J, et al. Estimation of load for tunnel lining in elastic soil using physics-informed neural network[J]. Computer-Aided Civil and Infrastructure Engineering, 2024, 39(17): 2701–2718.
- [22] IWASAKI Y, LAI C Y. One-dimensional ice shelf hardness inversion: Clustering behavior and collocation resampling in physics-informed neural networks[J]. Journal of Computational Physics, 2023, 492: 112435.
- [23] NING Luyuan, CAI Zhenwei, DONG Han, et al. A peridynamic-informed neural network for continuum elastic displacement characterization[J]. Computer Methods in Applied Mechanics and Engineering, 2023, 407: 115909.
- [24] REN Xiaodan, LYU Xianrui. Mixed form based physics-informed neural networks for performance evaluation of two-phase random materials[J]. Engineering Applications of Artificial Intelligence, 2024, 127: 107250.
- [25] ZHANG Xiaoping, ZHU Yan, WANG Jing, et al. GW-PINN: A deep learning algorithm for solving groundwater flow equations[J]. Advances in Water Resources, 2022, 165: 104243.
- [26] CHEN Lin, LI Ben, LUO Chenyi, et al. WaveNets: Physics-informed neural networks for full-field recovery of rotational flow beneath large-amplitude periodic water waves[J]. Engineering with Computers, 2024, 40(5): 2819–2839.
- [27] ALKHADHR S, ALMEKKAWY M. Physics-informed neural networks with resampling technique to model ultrasound wave propagation of a multi-element transducer[C]//2022 IEEE International Ultrasonics Symposium (IUS). Venice: IEEE, 2022: 1–4.
- [28] ZHOU Wen, MIWA S, OKAMOTO K. Advancing fluid dynamics simulations: A comprehensive approach to optimizing physics-informed neural networks[J]. Physics of Fluids, 2024, 36(1): 013615.
- [29] LIU Haiyi, ZHANG Yabin, WANG Lei. Pre-training physics-in-

- formed neural network with mixed sampling and its application in high-dimensional systems[J]. *Journal of Systems Science and Complexity*, 2024, 37(2): 494–510.
- [30] DAI Qianwei, ZHOU Wei, HE Run, et al. A data assimilation methodology to analyze the unsaturated seepage of an earth-rock-fill dam using physics-informed neural networks based on hybrid constraints[J]. *Water*, 2024, 16(7): 1041.
- [31] WANG Tian, BAI Zhaowei, ZHAO Haixia. Effects of sampling strategies and optimization methods on solving wave equation with physics-informed neural network[C]//IGARSS 2023–2023 IEEE International Geoscience and Remote Sensing Symposium. Pasadena: IEEE, 2023: 2215–2218.
- [32] HANNA J M, AGUADO J V, COMAS-CARDONA S, et al. Residual-based adaptivity for two-phase flow simulation in porous media using physics-informed neural networks[J]. *Computer Methods in Applied Mechanics and Engineering*, 2022, 396: 115100.
- [33] WU Chenxi, ZHU Min, TAN Qinyang, et al. A comprehensive study of non-adaptive and residual-based adaptive sampling for physics-informed neural networks[J]. *Computer Methods in Applied Mechanics and Engineering*, 2023, 403: 115671.
- [34] GAO Zhiwei, YAN Liang, ZHOU Tao. Failure-informed adaptive sampling for PINNs[J]. *SIAM Journal on Scientific Computing*, 2023, 45(4): A1971–A1994.
- [35] ESHKOFTI K, HOSSEINI S M. A new modified deep learning technique based on physics-informed neural networks (PINNs) for the shock-induced coupled thermoelasticity analysis in a porous material[J]. *Journal of Thermal Stresses*, 2024, 47(6): 798–825.
- [36] HOU Jie, LI Ying, YING Shihui. Enhancing PINNs for solving PDEs via adaptive collocation point movement and adaptive loss weighting[J]. *Nonlinear Dynamics*, 2023, 111(16): 15233–15261.
- [37] LIU Jianan, HOU Qingzhi, WEI Jianguo, et al. ESR-PINNs: Physics-informed neural networks with expansion-shrinkage resampling selection strategies[J]. *Chinese Physics B*, 2023, 32(7): 070702.
- [38] ZONG Yifei, HE Qizhi, TARTAKOVSKY A M. Improved training of physics-informed neural networks for parabolic differential equations with sharply perturbed initial conditions[J]. *Computer Methods in Applied Mechanics and Engineering*, 2023, 414: 116125.
- [39] MAO Zhiping, MENG Xuhui. Physics-informed neural networks with residual/gradient-based adaptive sampling methods for solving partial differential equations with sharp solutions[J]. *Applied Mathematics and Mechanics (English Edition)*, 2023, 44(7): 1069–1084.
- [40] LI Jinwu, LONG Xiangyun, DENG Xinyang, et al. A principled distance-aware uncertainty quantification approach for enhancing the reliability of physics-informed neural network[J]. *Reliability Engineering & System Safety*, 2024, 245: 109963.
- [41] AIKAWA Y, UEDA N, TANAKA T. Improving the efficiency of training physics-informed neural networks using active learning[J]. *New Generation Computing*, 2024, 42(4): 739–760.
- [42] JIANG Xinchao, WANG Xin, WEN Ziming, et al. Practical uncertainty quantification for space-dependent inverse heat conduction problem via ensemble physics-informed neural networks[J]. *International Communications in Heat and Mass Transfer*, 2023, 147: 106940.

(责任编辑 聂爱兰)